

金融长文本Agent的动态记忆压缩与高效问答挑战


方法说明与一键复现报告

项目	说明
团队名称	【待填写参赛队伍名】
报告状态	草稿 / 待冻结运行
正式模型	qwen3.6-plus
正式运行	待冻结；100 题单次端到端，不续跑、不跨运行选答
方法边界	纯词法检索 + Qwen 语义判断；不使用 embedding/向量库

本方案把长文压缩为按题构造、带页码和文档身份的短期工作记忆。所有语义判断只由同一次运行中的 Qwen 完成；答案、reasoning、证据、原始 API usage 与最终 CSV 可逐题联结。正式入口遇到缺失、解析失败或审计不守恒时直接终止，不使用默认答案补齐。

报告范围：数据预处理、检索与动态记忆、Qwen 调用协议、完整参数与提示词位置、Token 记账、证据和日志、随机性、失败策略、合规边界、一键复现命令，以及冻结运行的机械指标。报告仅陈述冻结流水线自身的可验证方法和产物。

01 总体架构与设计原则



核心目标是在证据可追溯的前提下降低重复上下文。压缩单位不是预先生成的语义摘要，而是由当前问题触发、从原文截取的页级窗口；同一批题摊薄公共协议和调用开销，每题证据仍在自己的逻辑命名空间完整内联。共享调用的逐题 Token按书面确认口径，以字符归属和整数最大余数法确定性守恒分摊。

六层流水线

层	输入 -> 输出	确定性/模型边界
1 数据层	官方 PDF/HTML/TXT -> 带页码文本与标题元数据	确定性解析；非 Qwen 工具仅恢复结构
2 候选层	题面 -> 词法相关文档候选	字符 unigram/bigram BM25 和金融写法归一
3 文档层	候选卡 -> 相关 doc_id	题目未给 doc_ids 时由 Qwen 选择
4 记忆层	选中文档 -> 带页码原文窗口	按题检索、去重、预算截断、证据编号
5 推理层	工作记忆 + 题面 -> 答案 + reasoning	仅 qwen3.6-plus；必要时稀疏复核
6 审计层	调用/证据/结果 -> CSV 与证据包	usage 守恒、来源核验、fail-closed

内容不变量

- 正式问题按题面、选项、领域与有序来源列表的内容指纹排序和分组；题集输入顺序与 qid 拼写不参与语义路由，来源位置语义被保留。
- 模型可见批次仅使用 ITEM_01、SRC_01 等局部编号；官方 qid 只作为调用前后审计、Token 分摊、账本和 CSV 的本地关联键，不进入 messages。
- 答案与 reasoning 由同一个被记录的 Qwen 响应产生；后处理仅执行官方 schema 的机械格式化。

02 预处理、纯词法检索与动态记忆

573	0	字符 1-2 gram	页级原文
冻结文档数	embedding / 向量模型	BM25 基本词元	证据最小单元

确定性预处理

- PyMuPDF 提取 PDF 文本、页码和基础版面信息；BeautifulSoup 与 lxml 清洗 HTML；TXT 原样规范化。本链不声称恢复表格结构。
- HTML `summary` 是原网页 meta description 折叠空白后的 160 字符节选；标题修复只用版面和结构线索。二者都不是模型语义摘要，也不注入外部知识。
- processed_data 与原始语料分别记录逐文件 bytes、SHA256 和规范树哈希；rebuild_processed.py 可从官方 raw 目录重建。

词法候选与写法归一

- 检索器使用字符 unigram/bigram BM25，适配中文无空格文本；每个查询在文档内归一，重复窗口跨查询累加相关度。
- 年份、季度、同比方向和常见金融表述只做可解释的词法扩展，不建立稠密向量或外部知识库。
- 若题目未指定文档，先以词法召回形成候选卡，再由同一正式 Qwen 模型在候选范围内选择 doc_id。

按题动态工作记忆

步骤	处理	压缩/审计效果
查询构造	题干、各选项、年份/实体/口径词形成多查询	避免只由一条宽泛查询主导
原文检索	每条查询从指定文档召回页级窗口	保留 doc_id、page 与原文片段
合并去重	相同窗口合并并累加归一相关度，再按文档轮询	兼顾多查询共识与多文档覆盖
预算装配	按冻结上限装配；计算锚点先锁定，选项锚点安全换位	不扩容；不可行即终止，预算可复核
缺证扩展	明确报告缺数时扩大词法窗口	仅由可见缺证状态触发，不按题号触发

“记忆压缩”在本实现中是可逆的证据选择：压缩后的每一段都能回到原始 doc_id和页码，不把模型生成摘要当作事实来源。

03 Qwen 推理协议、计算题与提示词定位

所有正式语义调用使用 DashScope OpenAI-compatible API 的 qwen3.6-plus。本地代码只负责证据装配、调用编排、格式解析和审计，不使用第二类语义模型。

选择题批处理

- 紧凑/标准题最多 4 题、复杂题最多 2 题组成一批；按可见内容复杂度冻结证据/thinking 为 compact=4200/关闭、standard=5200/1000、deep=5200/1600，不读取 qid 或历史结果。
- 主调用同时返回逐项答案与 20 字以上 reasoning。只有响应显式 NEED_REVIEW 或无法解析时，才以同证据触发单题稀疏复核。
- 多选答案在解析后仅做字母去重升序；单选/判断和多槽位均按官方模板确定格式。

计算与抽取题

- 通用协议为“带页码取数 -> 绑定表头/口径/单位 -> 写出列式 -> 单位检查 -> 按槽位舍入”。
- 首轮明确报告缺失字段时，扩大纯词法证据后调用 calc1b；未解决歧义或槽位无效时才进入 calc_review。
- 不存在固定题号 handler、答案常量或对某一道正式题的提示词分支。

完整提示词索引

调用 tag	代码位置	触发与用途
docsel / docsel_format_retry	agent/doc_select.py: select_docs(_batch)	缺少 doc_ids 时选文档；JSON 失败时只修格式
generic_batch_main	agent/batch_generic.py: answer_batch	选择题批主调用，同次生成答案和 reasoning
generic_batch_review	agent/batch_generic.py: answer_batch	NEED_REVIEW 或无法解析时单题复核
calc1 / calc1b / calc_review	agent/calc.py: answer_calc	取数计算、明确缺数扩展、最终歧义核验

每次请求的完整 messages、模型名和 thinking/max_tokens 参数均写入 api_calls.jsonl。其 provider_response 保留服务端 id/created/model/system_fingerprint/finish_reason、未 strip 的 message content/reasoning_content 与含扩展字段的完整原始 usage；解析用规范化字段另存并交叉核对。

04 冻结参数与 Token 守恒记账

正式非秘密配置

环境变量	冻结值
AFAC_BATCH_MAX	4
AFAC_DEEP_BATCH_MAX	2
AFAC_CHOICE_EVIDENCE_CHARS	5200
AFAC_CHOICE_COMPACT_EVIDENCE_CHARS	4200
AFAC_CHOICE_COMPACT_THINKING	0
AFAC_CHOICE_THINKING_BUDGET	1000
AFAC_CHOICE_DEEP_THINKING_BUDGET	1600
AFAC_CHOICE_MAX_TOKENS_PER_ITEM	320
AFAC_REVIEW_THINKING_BUDGET	1400
AFAC_REVIEW_MAX_TOKENS	700
AFAC_CALC_EVIDENCE_CHARS	6000
AFAC_CALC_THINKING_BUDGET	1250
AFAC_CALC_MAX_TOKENS	3600
AFAC_DOCSEL_BATCH_MAX	8
AFAC_DOCSEL_MAX_TOKENS_PER_ITEM	110
PYTHONHASHSEED	0

API 公共参数

项目	值	说明
endpoint	https://dashscope.aliyuncs.com/compatible-mode/v1	OpenAI-compatible HTTPS API
model	qwen3.6-plus	文档选择、作答、计算和复核一致
temperature	0.1	显式固定；不发送不可移植本地 seed
timeout	300 秒	单请求超时
transport retry	SDK=0；每个逻辑调用只尝试 1 次	无 provider usage 的异常使整次候选中止
top_p / stream / cache	不发送 / false / 不使用	无模型响应、检索结果或跨运行缓存

原始 usage 到逐题台账

- 文档选择批：prompt 权重 = 本题 ITEM 字符数 + 每张共享文档卡 $\max(1, \text{floor}(\text{卡字符数}/\text{拥有题数}))$ ；可见 completion 等权；异常出现的隐藏 reasoning 沿用 prompt 权重。
- 选择题作答批：prompt 权重 = 本题完整 ITEM 字符数 + $\max(1, \text{floor}((\text{intro}+\text{protocol 字符数})/\text{批大小}))$ ；隐藏 reasoning 沿用 prompt 权重；可见 completion 按解析用 BEGIN/END ITEM 区块去首尾空白后的字符数（最小 1），缺块记1、本地权重解析异常则全部记1。
- 非共享调用将 provider 整次原始 usage 直接归题；共享权重缺失/非法记0、全零才全记1，再用精确整数最大余数法（floor、余数降序、并列按既有顺序）逐字段守恒。Token 规范 afac-shared-token-allocation-v1；SHA256 1af0dae644fb4b4278ec2f9a9e7f02723d2fb36d2afd149f20d57cd335d4a6e9；验收比较规范 afac-acceptance-comparison-v1；SHA256 8f2de1ea90a8705100ae0d4f8d0624c84118d043e17093a91886a1aa923140dc。这些逐题值不冒充 provider 逐题返回。

05 证据、日志、随机性与失败终止

单次运行产物及联结

产物	记录内容	机械核验
answer.csv / answers.json	最终 100 题、多槽答案与逐题 Token	题集、顺序、summary 与 schema 一致
reasonings.json	每题最终可见推理摘要	不少于 20 个非空白字符
reasoning_sources.json	选中阶段、原始 trace、证据 ID	reasoning 必须逐字存在于成功响应
api_calls.jsonl	完整请求、未 strip 响应、provider 元数据与完整原始 usage	完整候选仅含单次成功调用；异常运行终止
token_ledger.json	调用级及逐题整数分摊	调用级与全卷守恒
docsel_log / run_log	文档选择、原始答案、解析与阶段	与答案、来源和 evidence 交叉联结
evidence.json	doc_id、page、quoted_clause、调用引用	每题均有非空原文证据
run_config.json	环境、命令、版本、输入/运行清单	冻结 runtime 和 input 的 SHA256

确定性与剩余方差

- 文档解析、词法索引、内容指纹排序、批分组、证据去重、schema 格式化、整数分摊和哈希均为确定性步骤；PYTHONHASHSEED=0。
- 并发只改变墙钟时间，不改变内容排序；输出按官方输入顺序回写。
- 剩余方差来自云端模型版本和 temperature=0.1 的服务端采样；网络异常直接中止，不在同一候选内重试。

Fail-closed 条件

触发	正式行为
输出目录已存在	拒绝运行，避免续跑或覆盖
不是 100 个唯一 qid / schema 不一致	运行前立即终止
文档选择为空、答案槽为空、reasoning 过短	不写默认值，整次失败
API 请求异常或解析/证据联结失败	保留部分记录并终止；不可打包
Token 不守恒、runtime/input 哈希变化	检查器拒绝验收

06 合规边界与一键复现

正式流水线仅消费官方题目、官方长文、官方 submit.csv、冻结 processed_data 和本次Qwen 响应。正式运行清单只包含本次输入、代码配置、模型响应与生成产物。

合规边界

- 不使用 embedding、dense retrieval、向量数据库或非 Qwen 语义排序；非 Qwen 工具只用于文件解析和确定性格式处理。
- 所有路由只由可见题面、schema 与候选原文内容触发；不包含 qid/顺序条件、固定题 handler、答案常量或跨运行候选选择。
- 官方明确命名的百分号槽位仅作为 schema 例外，并绑定规则文件哈希和原文位置；它不参与语义判断。
- API key 只由 DASHSCOPE_API_KEY 在运行时注入，不写入日志、PDF 或提交包。

环境安装与离线完整性检查

```
python -m pip install -r requirements.txt
export DASHSCOPE_API_KEY='your-key'
./generate_answer.sh --check-runtime
./verify_package.sh
```

完整推理耗时预估与资源需求

项目	建议/预估	主要因素
100 题端到端	约 10-30 分钟；以正式 run_summary 为准	Qwen 网络/服务延迟、长上下文、缺证扩展和稀疏复核
本地资源	CPU≥8 核；RAM≥16GB；磁盘≥2GB；workers=6	BM25/原文装配；无需 GPU 与显存

正式 100 题单次运行

```
./generate_answer.sh \
--input /absolute/path/to/this-runtime/upload_b \
--output /path/to/afac-repro-20260802-team01 \
--model qwen3.6-plus \
--workers 6
```

--input 必须解析为本 runtime 内固定的 upload_b (其中已有 question_b/ 与 submit.csv)；外部字节副本会在建锁前拒绝。输出目录必须不存在。一键入口会依次运行正式 Agent、build_evidence.py 与零 API 的 check_reproduction.py；任何门禁失败都返回非零退出码。README.md、DATA_PROVENANCE.md、MODEL_AND_API.md 与 PROMPT_AND_CONFIG_MAP.md 提供数据、模型和源码索引。

07 冻结运行指标与材料指纹

当前为排版演示稿；冻结运行目录尚未完整生成。以下所有运行指标都以“待生成”标记，不能作为提交材料。正式版必须在单次冻结运行和严格检查通过后重新生成。

运行与调用统计

指标	记录值	来源
运行时间	待生成	run_config.json
唯一正式 run ID	待冻结	run_start_attestation.json
冻结 commit	待冻结	run_config.json / git_dirty=待验证
模型 / workers	qwen3.6-plus / 待生成	run_config.json
选择题批 / 计算题	待生成 / 待生成	run_summary.json
prompt / completion	待生成 / 待生成	三处总计交叉核对
逐题 Token min / median / max	待生成 / 待生成 / 待生成	token_ledger.json
成功调用 / 中止异常 / 额外传输尝试	待生成 / 待生成 / 待生成	api_calls.jsonl
本地材料门禁	未执行: 待冻结运行	报告生成时只读核验

输入、运行时与核心产物指纹

对象	文件数/字节	SHA256 (前 16 位)
input manifest	官方题目文件 + submit.csv	待生成
runtime manifest	待生成 files / 待生成 bytes	待生成
answer.csv	本次运行	待生成
evidence.json	本次运行	待生成
api_calls.jsonl	本次运行	待生成
token_ledger.json	本次运行	待生成

成功调用 tag 分布

待冻结运行后生成

本页只报告当前冻结运行自身的可验证指标，不在报告生成阶段读取额外评价数据或修改运行产物。正式提交前还应由官方复现流程独立核验准确率、推理过程分和允许误差。

未来拓展方向

在不改变本次冻结候选的前提下，可继续研究表格结构的确定性恢复、选项级证据覆盖诊断、按可见复杂度自适应的记忆预算，以及服务端模型版本固定；任何扩展都应作为新的独立运行重新审计，不能据本次验收结果回改答案或账本。

FORMAL_RUN_ID: 待冻结

RUN_ATTESTATION_SHA256: 待生成

SOURCE_COMMIT: 待冻结

TOKEN_ALLOCATION_SPEC_SHA256: 1af0dae644fb4b4278ec2f9a9e7f02723d2fb36d2afd149f20d57cd335d4a6e9

ACCEPTANCE_COMPARISON_SPEC_SHA256: 8f2de1ea90a8705100ae0d4f8d0624c84118d043e17093a91886a1aa923140dc